TP2 – Intégration MLOps complète

(GitHub Actions, DVC, CML, Docker, Google Drive)

Oussama Khouya Radwane Khemisse

8 décembre 2025

1 Contexte et objectifs

Projet `ml-dvc-iris` complété avec un pipeline `DVC` (`prepare` → `train` → `evaluate`), génération automatique de rapport CML et artefacts stockés sous `metrics/` et `models/`. Objectifs : CI GitHub Actions, rapport CML, remote DVC Google Drive, containerisation Docker et promotion automatique du meilleur modèle.

2 Vérification du projet de départ

- Pipeline DVC existant : `dvc.yaml` (extrait **??**).
- Données et artefacts présents : `data/iris.csv`, `data/iris_preprocessed.csv`, `models/random_forest` `metrics/*.json`.
- Exécution locale du pipeline `dvc repro` réussie (**??**).

Listing 1 – Pipeline DVC

```
stages:
  prepare:
    cmd: python scripts/preprocess.py
    deps:
      - scripts/preprocess.py
      - data/iris.csv
    outs:
      - data/iris_preprocessed.csv

  train:
    cmd: python src/train.py
    deps:
      - src/train.py
      - data/iris_preprocessed.csv
      - params.yaml
    outs:
      - models/random_forest.pkl
      - metrics/train_metrics.json

  evaluate:
    cmd: python src/evaluate.py
    deps:
      - src/evaluate.py
      - models/random_forest.pkl
      - data/iris_preprocessed.csv
    outs:
      - metrics/eval_metrics.json
```

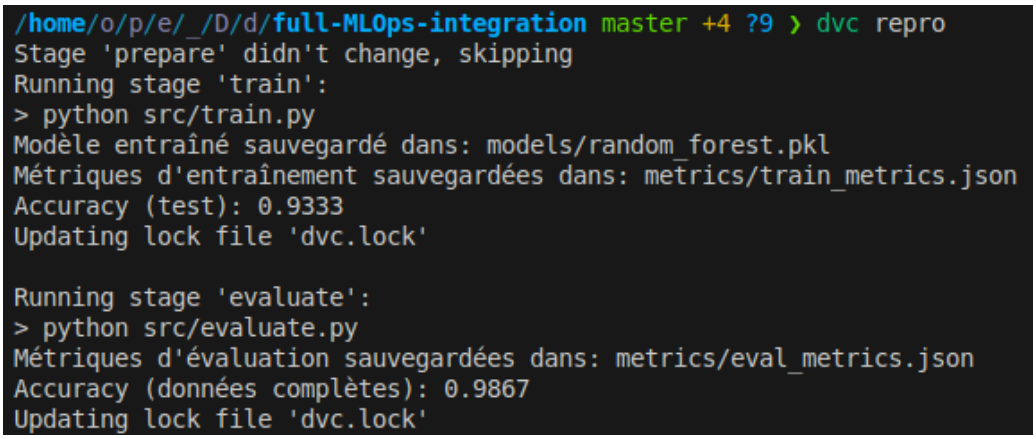

FIGURE 1 – Commande `dvc repro` exécutée avec succès

3 Workflow GitHub Actions avec DVC et CML

3.1 Dépendances Python

— Fichier `requirements.txt` incluant bibliothèques ML, DVC et CML (**??**).

3.2 Script de rapport CML

— `scripts/generate_cml_report.py` lit les métriques JSON et produit `reports/cml_report.md`.
— Exécution manuelle : `python3 scripts/generate_cml_report.py` (**??**) ; aperçu du rapport généré (**??**).

Listing 2 – Extrait – génération du rapport CML

```
report_text = build_markdown(train_metrics, eval_metrics)
os.makedirs(REPORTS_DIR, exist_ok=True)
OUTPUT_PATH.write_text(report_text)
```

3.3 Workflow CI attendu

— Déclencheurs : `push` et `pull_request`.
— Étapes : checkout, installation Python & dépendances, `dvc pull`, `dvc repro`, `python3 scripts/generate_cml_report.py`, publication du commentaire CML sur la PR.
— Implémentation à ajouter dans `.github/workflows/mlops-pipeline.yml` (non encore présente dans ce dépôt).

4 Remote DVC Google Drive

— Remote attendu : `dvc remote add -d gdrive_remote gdrive://<ID_DOSSIER>`, suivi de `dvc push`.
— Statut actuel : aucune configuration remote dans `.dvc/config` ; à compléter avec les identifiants de service Google et un secret CI.

5 Containerisation Docker

— Dockerfile attendu : image `python:3.11-slim`, installation `requirements.txt`, copie du projet, `CMD ["dvc","repro"]`.

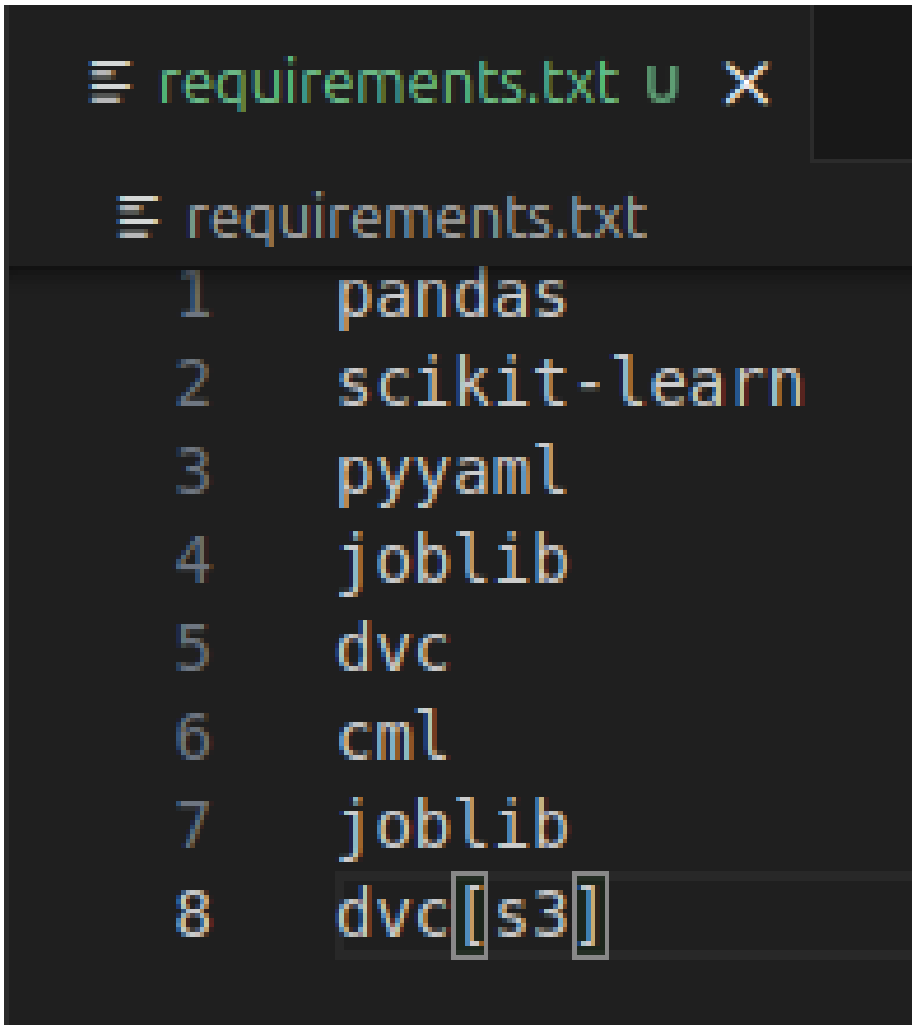

FIGURE 2 – Dépendances Python (`requirements.txt`)

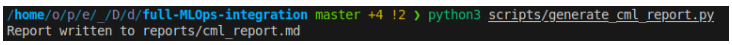

FIGURE 3 – Commande de génération du rapport CML

— Commandes de validation : `docker build -t ml-dvc-iris:latest .` puis `docker run -rm ml-dvc-iris:latest`.
— Statut actuel : Dockerfile à ajouter.

6 Test end-to-end sur Pull Request

— Branches de test : `feature/test-mlops` puis PR vers `main`.
— Attendus : pipeline CI vert, rapport CML commenté dans la PR.
— Statut : à activer une fois le workflow CI poussé.

7 Déploiement automatique du meilleur modèle

— Script `scripts/deploy.py` à implémenter : comparaison de l'accuracy courante (`metrics/eval_metrics` avec `metrics/best_metrics.json` ; copie vers `models/production_model.pkl` en cas d'amélioration.

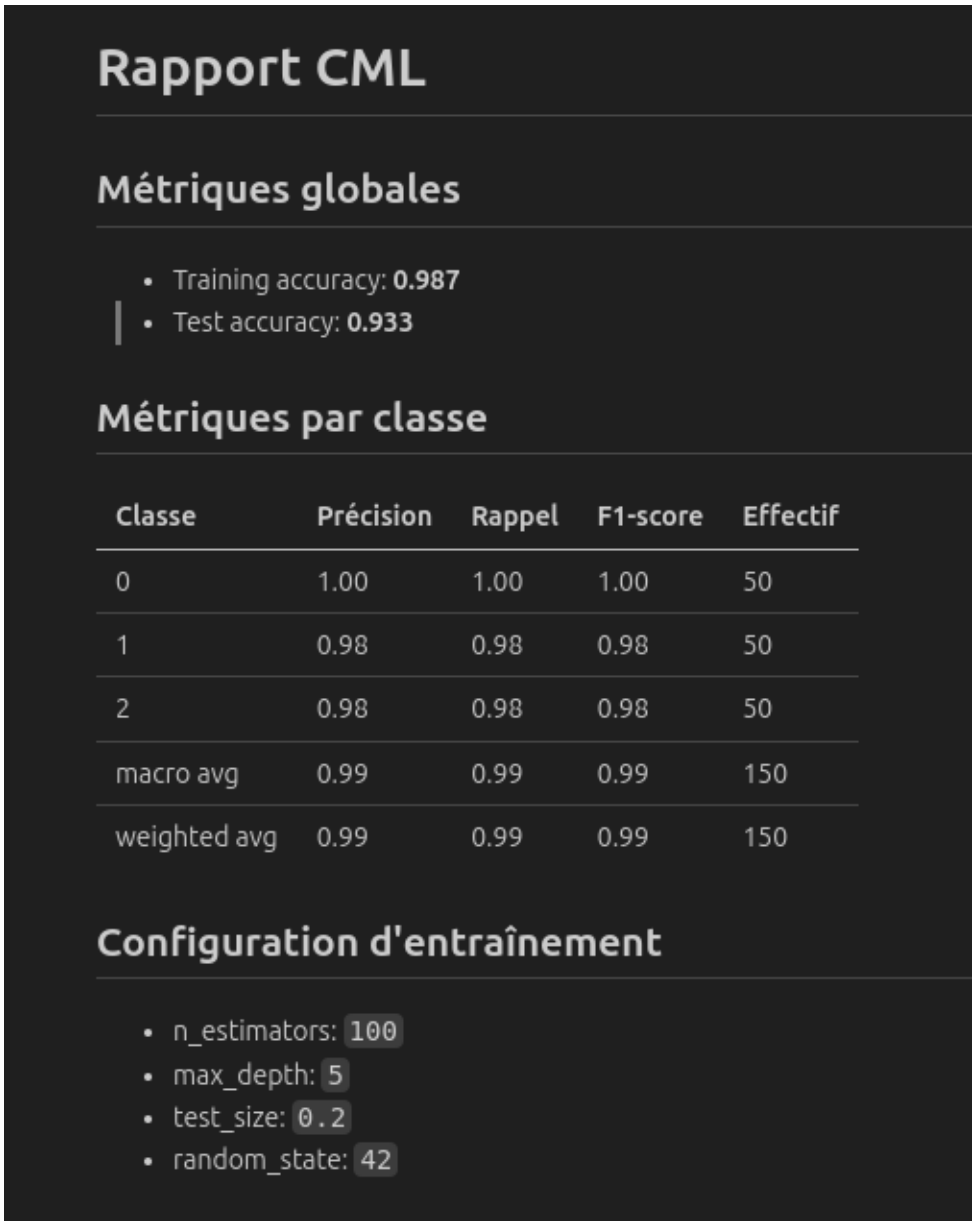

Rapport CML

Métriques globales

- Training accuracy: **0.987**
- Test accuracy: **0.933**

Métriques par classe

Classe	Précision	Rappel	F1-score	Effectif
0	1.00	1.00	1.00	50
1	0.98	0.98	0.98	50
2	0.98	0.98	0.98	50
macro avg	0.99	0.99	0.99	150
weighted avg	0.99	0.99	0.99	150

Configuration d'entraînement

- n_estimators: `100`
- max_depth: `5`
- test_size: `0.2`
- random_state: `42`

FIGURE 4 – Rapport CML produit (`reports/cml_report.md`)

— Stage DVC `deploy` à ajouter dans `dvc.yaml` dépendant de `models/random_forest.pkl` et produisant `models/production_model.pkl`.
— Statut actuel : non présent, à compléter.

8 Conclusion

Chaîne MLOps en place localement : pipeline DVC fonctionnel et génération de rapport CML automatisée. À finaliser : ajout du workflow GitHub Actions, configuration du remote Google Drive, Dockerfile et stage de déploiement pour promouvoir automatiquement le meilleur modèle. Les captures fournies documentent l'exécution locale du pipeline (**??**) et la génération du rapport CML (**??**, **??**).