

TP2 – Intégration MLOps complète

(GitHub Actions, DVC, CML, Docker, Google Drive)

Oussama Khouya

Radwane Khemisse

Achrafe Elalaoui

9 décembre 2025

1 Contexte et objectifs

Contexte : projet `ml-dvc-iris` du TP1 (dataset Iris, pipeline DVC).

Objectifs du TP2 :

1. Intégrer le pipeline DVC dans un workflow GitHub Actions.
2. Générer un rapport de métriques avec CML dans les Pull Requests.
3. Configurer un remote DVC Google Drive pour les données et artefacts.
4. Préparer un Dockerfile et la promotion du meilleur modèle vers `models/production_model.pkl`.

2 Architecture MLOps mise en place

L'architecture MLOps repose sur un pipeline DVC défini dans `dvc.yaml` avec plusieurs stages et le suivi des données et artefacts (`data/iris.csv`, `data/iris_preprocessed.csv`, `models/random_forest.pkl`, `metrics/*.json`). Un remote DVC `new_gdrive` sur Google Drive est configuré pour stocker ces artefacts. Un workflow GitHub Actions `mlops-pipeline.yaml` exécute automatiquement `dvc pull`, `dvc repro` et le script `scripts/generate_cml_report.py` afin de produire un rapport CML et un commentaire automatique sur les Pull Requests, en préparation d'une future containerisation Docker et d'un stage `deploy` pour promouvoir le meilleur modèle.

3 Vérification du projet de départ

Les vérifications de base du projet se font en deux étapes :

1. Cloner (ou mettre à jour) le projet `ml-dvc-iris` sur la machine locale.
2. Vérifier que la commande suivante s'exécute localement : `dvc repro` (figure 1).

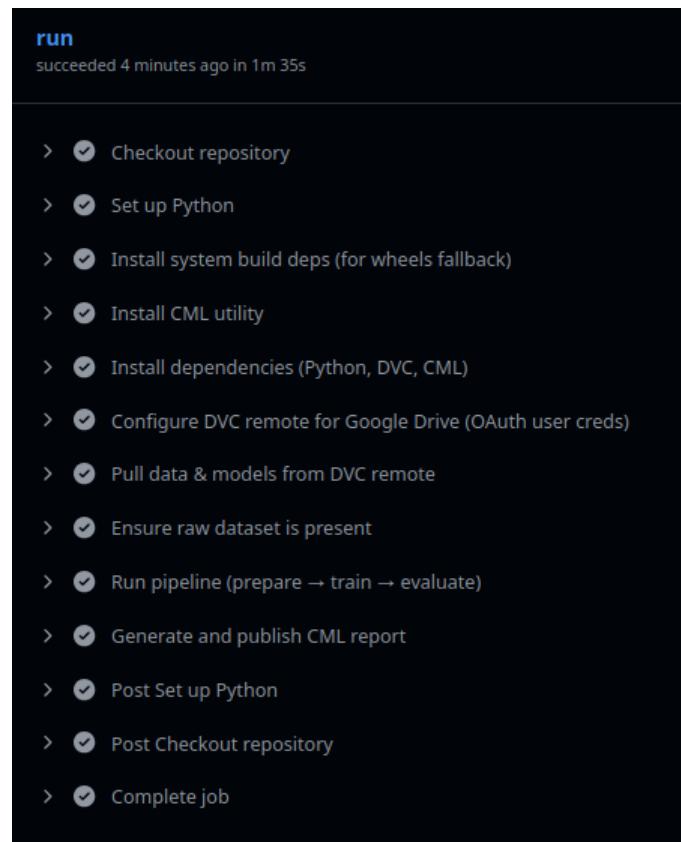
```
/home/o/p/e/_D/d/full-MLOps-integration master +4 ?9 > dvc repro
Stage 'prepare' didn't change, skipping
Running stage 'train':
> python src/train.py
Modèle entraîné sauvagardé dans: models/random_forest.pkl
Métriques d'entraînement sauvagardées dans: metrics/train_metrics.json
Accuracy (test): 0.9333
Updating lock file 'dvc.lock'

Running stage 'evaluate':
> python src/evaluate.py
Métriques d'évaluation sauvagardées dans: metrics/eval_metrics.json
Accuracy (données complètes): 0.9867
Updating lock file 'dvc.lock'
```

FIGURE 1 – Exécution locale du pipeline `dvc repro`

4 Workflow GitHub Actions avec DVC et CML

4.1 Exécution réussie du pipeline GitHub Actions



The screenshot shows a successful GitHub Actions run titled "run". It succeeded 4 minutes ago in 1m 35s. The list of completed steps includes:

- > ✓ Checkout repository
- > ✓ Set up Python
- > ✓ Install system build deps (for wheels fallback)
- > ✓ Install CML utility
- > ✓ Install dependencies (Python, DVC, CML)
- > ✓ Configure DVC remote for Google Drive (OAuth user creds)
- > ✓ Pull data & models from DVC remote
- > ✓ Ensure raw dataset is present
- > ✓ Run pipeline (prepare → train → evaluate)
- > ✓ Generate and publish CML report
- > ✓ Post Set up Python
- > ✓ Post Checkout repository
- > ✓ Complete job

FIGURE 2 – Exécution réussie du pipeline GitHub Actions

4.2 Commentaire CML dans une Pull Request



FIGURE 3 – Commentaire CML généré dans la Pull Request

5 Remote DVC Google Drive

- Remote new_gdrive pointant vers l'ID Drive, authentifié via secrets OAuth.

Listing 1 – Extrait .dvc/config

```
[core]
remote = new_gdrive

[remote "new_gdrive"]
url = gdrive://1qnTG-xYstcnUbljTv94pp2izEqLpBP-o
gdrive_use_service_account = true
gdrive_service_account_json_file_path = /home/oldhome/pc/enset/_S3/
DevOps/dvc/gdrive_user_credentials.json
```

- Synchronisation vérifiée : dvc pull ([figure 4](#)) et dvc push ([figure 5](#)).

```
/home/o/p/e/_D/d/full-MLOps-integration main !2 ?3 > ls data/ 4s
[] iris.csv.dvc

/home/o/p/e/_D/d/full-MLOps-integration main ?3 > dvc pull
Collecting
Fetching
Building workspace index
Comparing indexes
Applying changes
A      data/iris_preprocessed.csv
1 file added

/home/o/p/e/_D/d/full-MLOps-integration main ?3 > ls data/    4s
[] iris.csv.dvc [] iris_preprocessed.csv
```

FIGURE 4 – Récupération des artefacts par dvc pull

```
/home/o/p/e/_D/d/full-MLOps-integration main ?2 > dvc push
Collecting
Pushing
Everything is up to date.
```

FIGURE 5 – dvc push indiquant un cache distant à jour

- Structure de Remote DVC (google drive) : ([figure 6](#)).




FIGURE 6 – structure dossier dvc (google drive)

6 Containerisation Docker

6.1 Création du fichier Dockerfile

À la racine du projet, nous créons un fichier `Dockerfile` qui part de l'image `python:3.11-slim`, installe les dépendances et lance `dvc repro` par défaut. Extrait :

Listing 2 – Extrait du fichier Dockerfile

```
FROM python:3.11-slim

WORKDIR /app

COPY requirements.txt .
RUN pip install --no-cache-dir --upgrade pip && \
    pip install --no-cache-dir -r requirements.txt

COPY . .

CMD ["dvc", "repro"]
```

6.2 Construction de l'image et test local sur un conteneur

Étapes :

1. Construire l'image : `docker build -t ml-dvc-iris:latest .` ([figure 7](#)).
2. Lancer un conteneur de test : `docker run -rm ml-dvc-iris:latest` ([figure 8](#)).

```
[+] Building 2880.2s (10/10) FINISHED docker:rootless
  => [internal] load build definition from Dockerfile          0.1s
  => => transferring dockerfile: 379B                         0.0s
  => [internal] load metadata for docker.io/library/python:3.11-slim 2.9s
  => [internal] load .dockerignore                            0.0s
  => => transferring context: 2B                           0.0s
  => [1/5] FROM docker.io/library/python:3.11-slim@sha256:193fdd0bbcb3d2a 172.3s
  => => resolve docker.io/library/python:3.11-slim@sha256:193fdd0bbcb3d2ae6 0.1s
  => => sha256:1771569cc1299abc9cc762fc4419523e721b11a3927ef968 251B / 251B 0.4s
  => => sha256:b3dd773c329649f22e467ae63d1c612a039a0559de 14.36MB / 14.36MB 4.4s
  => => sha256:22b63e76fde1e200371ed9f3cee91161d192063bcff6 1.29MB / 1.29MB 4.0s
  => => sha256:0e4bc2bd6656e6e004e3c749af70e5650bac2258 29.78MB / 29.78MB 168.9s
  => => extracting sha256:0e4bc2bd6656e6e004e3c749af70e5650bac2258243eb0949 1.5s
  => => extracting sha256:22b63e76fde1e200371ed9f3cee91161d192063bcff65c9ab 0.3s
  => => extracting sha256:b3dd773c329649f22e467ae63d1c612a039a0559dec99ffb9 1.3s
  => => extracting sha256:1771569cc1299abc9cc762fc4419523e721b11a3927ef968a 0.0s
  => [internal] load build context                          57.4s
  => => transferring context: 632.78MB                      57.3s
  => [2/5] WORKDIR /app                                    0.0s
  => [3/5] COPY requirements.txt .                         0.0s
  => [4/5] RUN pip install --no-cache-dir --upgrade pip && pip insta 2599.0s
  => [5/5] COPY . .                                      9.6s
  => exporting to image                                  96.1s
  => => exporting layers                                60.6s
  => => exporting manifest sha256:0a78c9df6c7219782fdeff126261f75b36051e36e 0.0s
  => => exporting config sha256:36466bda8d878b0118cc1afdda3e374979b59f5ec9e 0.0s
  => => exporting attestation manifest sha256:9c89dd4d96970b1e2e4ea0f5fc18 0.0s
  => => exporting manifest list sha256:e84af8276834612500950a0eda14f1f20407 0.0s
  => => naming to docker.io/library/ml-dvc-iris:latest   0.0s
  => => unpacking to docker.io/library/ml-dvc-iris:latest 35.3s
```

FIGURE 7 – docker build output ([google drive](#))

```

) docker run --rm \
-v "$(pwd)/dvc.yaml:/app/dvc.yaml:ro" \
-v "$(pwd)/dvc.lock:/app/dvc.lock" \
-v "$(pwd)/data:/app/data" \
ml-dvc-iris:latest

Stage 'download' didn't change, skipping
Stage 'prepare' didn't change, skipping
Stage 'train' didn't change, skipping
Stage 'evaluate' didn't change, skipping
Data and ninelines are up to date

```

FIGURE 8 – Exécution du conteneur Docker

7 Promotion du meilleur modèle

- Attendu : script `scripts/deploy.py` et stage `deploy` produisant `models/production_model.pkl`.
- Statut : non implémenté, fichier `models/production_model.pkl` non généré.
- À faire : comparer `metrics/eval_metrics.json` à `metrics/best_metrics.json`, copier `models/random_forest.pkl` en cas de meilleure accuracy.

8 Difficultés rencontrées et solutions

- Docker build très long (48 minutes) pour construire l'image `ml-dvc-iris:latest` (voir [figure 7](#)).
- `iris.csv` non versionné par DVC car seulement `deps` et non `out`. Solution : ajouter `iris.csv` comme `out` dans `dvc.yaml` et faire `dvc push`.

Listing 3 – Extrait du nouveau fichier `dvc.yaml`

```

stages:
download:
  cmd: python scripts/download_iris.py
  deps:
    - scripts/download_iris.py
  outs:
    - data/iris.csv

prepare:
  cmd: python scripts/preprocess.py
  deps:
    - scripts/preprocess.py
    - data/iris.csv
  outs:
    - data/iris_preprocessed.csv

```

9 Conclusion

Chaîne MLOps quasi complète : pipeline DVC reproductible, remote Google Drive fonctionnel, workflow GitHub Actions + CML opérationnel avec rapport et commentaire PR. Travaux restants : containerisation Docker (build/run), ajout du stage `deploy` pour produire `models/production_model.pkl` et finaliser la promotion du meilleur modèle.